STL10 图像分类模型优化实验报告

人工智能原理课程· 项目二· STL10 图像分类

院　　系：	自动化系
班　　级：	自52班
学 生 姓 名：	刘江宇
学　　号：	2024013215
课 程 名 称：	人工智能原理

目录

1 实验目标 **2**

2 实验设置 **2**

3 实验分组 **2**

4 总体结果对比 **3**

5 训练曲线展示 **3**

5.1 Baseline 曲线（过拟合明显） 3
5.2 exp2_aug_bn 曲线（浅层 configurable 强基线） 4
5.3 exp3_aug_dropout 曲线 4
5.4 exp6_improved_long 曲线（6 卷积骨干） 4
5.5 exp7_improved_longer 曲线（测试准确率最佳） 5
5.6 exp8_improved_longer_12 曲线（12 卷积骨干） 5

6 混淆矩阵对比图 **6**

7 结果分析 **6**

7.1 1) 有效实验与主要收益来源 6
7.2 2) 优化器与学习率（exp4 / exp5） 6
7.3 3) 过拟合与模型深度 7
7.4 4) 最终测试集性能 7
7.5 5) 方法优劣总结 7

8 可解释性分析（Grad-CAM） **7**

8.1 方法说明 7
8.2 可视化设置 8
8.3 结果展示 8
8.4 分析与讨论 8
8.5 小结 8

9 结论 **8**

1 实验目标

基于 baseline CNN，在 STL10 数据集上开展优化实验，尝试在模型训练过程当中可能会影响模型效果的因素，更好地掌握上课学习到的内容重点比较不同因素对模型效果的影响，包括：

- 数据增强是否提升泛化能力；
- BatchNorm 与 Dropout 对收敛和过拟合的影响；
- 优化器与学习率设置对最终测试表现的影响；
- 更深网络（`improved_long`，多段池化）相对浅层 configurable 的收益。

同时还通过Grad-CAM进行可解释性的分析，更好地理解模型为什么能够做出这样的预测

2 实验设置

- 数据来源：`STL10/train` 与 `STL10/test`。（课程提供）
- 训练配置：固定 `epochs=50`、`batch_size=128`、`val_ratio=0.1`、`seed=42`。
- 评估指标：Accuracy、Macro-F1、Weighted-F1、分类报告、混淆矩阵。
- 输出目录：`outputs_improved/`。（可在压缩包或github上查看）

3 实验分组

- baseline：基础 CNN，无增强、无 BN、无 Dropout（Adam, lr=0.001, L2 `weight_decay=5e-4`）
- exp1_aug：数据增强（RandomCrop + HorizontalFlip + ColorJitter）
- exp2_aug_bn：数据增强 + BatchNorm
- exp3_aug_dropout：数据增强 + Dropout(0.3)
- exp4_aug_bn_sgd：与 exp2 相同（增强 + BN、无 Dropout），优化器改为 SGD（`lr=0.01`）
- exp5_aug_bn_lr：与 exp2 相同，Adam 学习率改为 `3e-4`
- exp6_improved_long：数据增强 + `improved_long`（6 个卷积层 + 六段空间下采样 + 分类头 Dropout），Adam `lr=1e-3`
- exp7_improved_longer：与 exp6 相同训练配方，网络为 `improved_longer`（**9** 个卷积层，无残差）
- exp8_improved_longer_12：与 exp7 相同训练配方，网络为 `improved_longer_12`（**12** 个卷积层，在 `improved_longer` 的 24×24 与 12×12 段各加深若干 128 通道卷积；无残差）

4 总体结果对比

实验组	Best Val Acc(%)	Test Acc(%)	Macro-F1	Weighted-F1
baseline	61.43	54.70	0.5464	0.5464
exp1_aug	71.57	66.50	0.6688	0.6688
exp2_aug_bn	77.14	71.70	0.7178	0.7178
exp3_aug_dropout	74.14	69.00	0.6918	0.6918
exp4_aug_bn_sgd	74.57	70.30	0.7052	0.7052
exp5_aug_bn_lr	74.43	69.80	0.6959	0.6959
exp6_improved_long	82.71	80.40	0.8055	0.8055
exp7_improved_longer	81.57	**81.60**	**0.8153**	**0.8153**
exp8_improved_longer_12	70.29	69.50	0.6948	0.6948

表 1: 各实验组性能对比（数据来自 `outputs_improved/comparison_summary.csv`）

5 训练曲线展示

5.1 Baseline 曲线（过拟合明显）

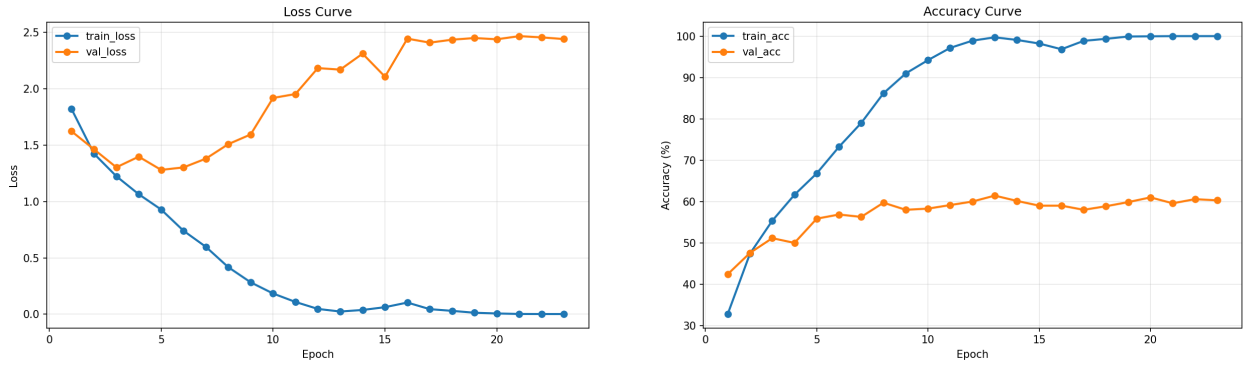

(a) Baseline Loss 曲线

(b) Baseline Accuracy 曲线

图 1: baseline 训练/验证曲线

5.2 exp2_aug_bn 曲线（浅层 configurable 强基线）

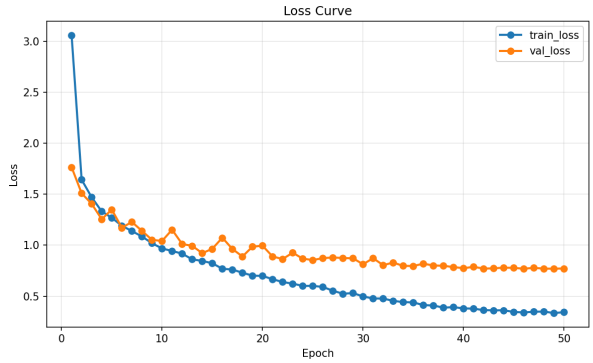

(a) exp2_aug_bn Loss 曲线

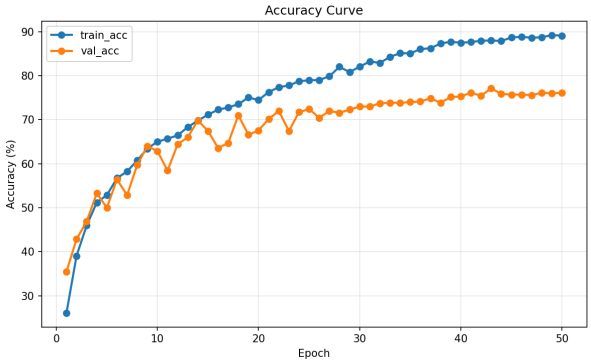

(b) exp2_aug_bn Accuracy 曲线

图 2: 数据增强 + BatchNorm 的训练/验证曲线

5.3 exp3_aug_dropout 曲线

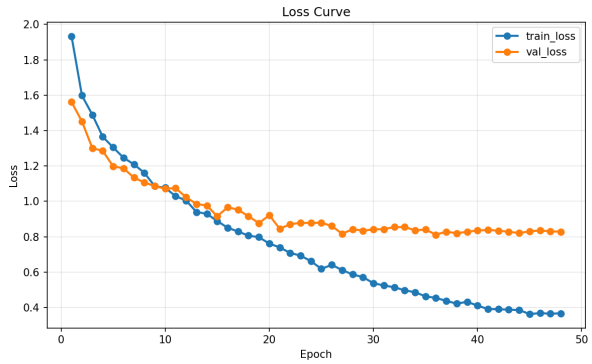

(a) exp3_aug_dropout Loss 曲线

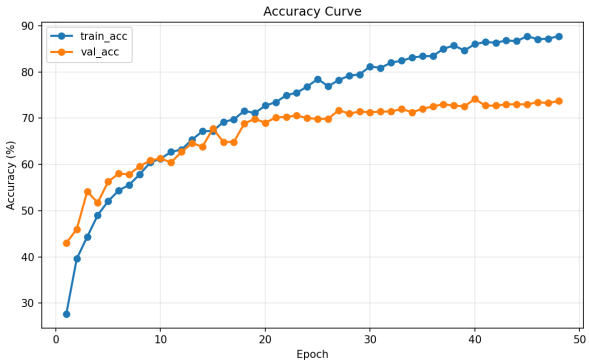

(b) exp3_aug_dropout Accuracy 曲线

图 3: 数据增强 + Dropout(0.3)、无 BatchNorm 的训练/验证曲线

5.4 exp6_improved_long 曲线（6 卷积骨干）

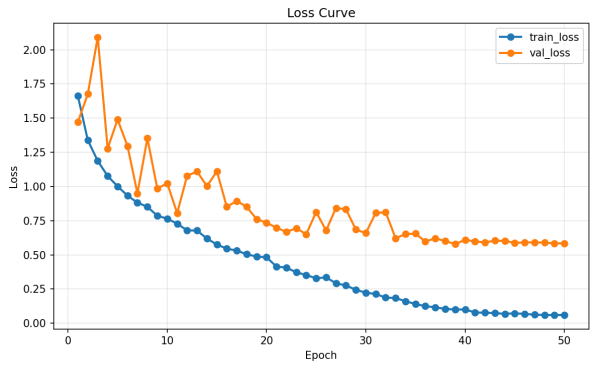

(a) exp6_improved_long Loss 曲线

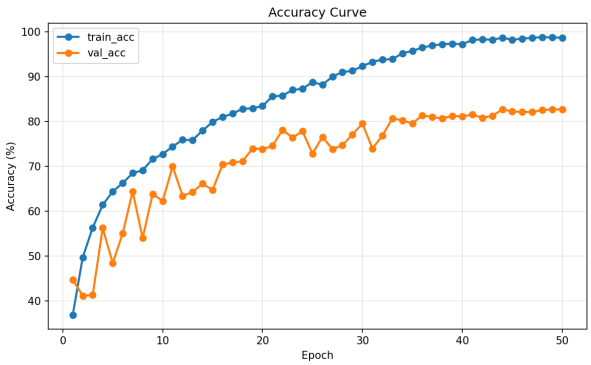

(b) exp6_improved_long Accuracy 曲线

图 4: 更深网络 `improved_long`（六段下采样）在增强 + Adam 下的训练/验证曲线

5.5 exp7_improved_longer 曲线（测试准确率最佳）

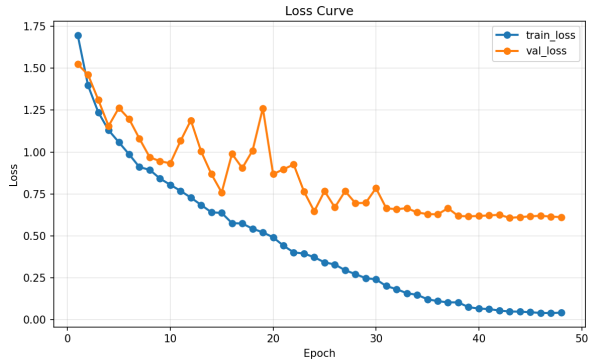

(a) exp7_improved_longer Loss 曲线

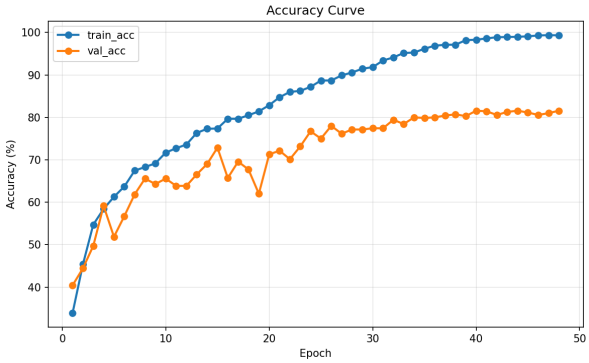

(b) exp7_improved_longer Accuracy 曲线

图 5: `improved_longer`（9 个卷积层、无残差）在增强 + Adam 下的训练/验证曲线

5.6 exp8_improved_longer_12 曲线（12 卷积骨干）

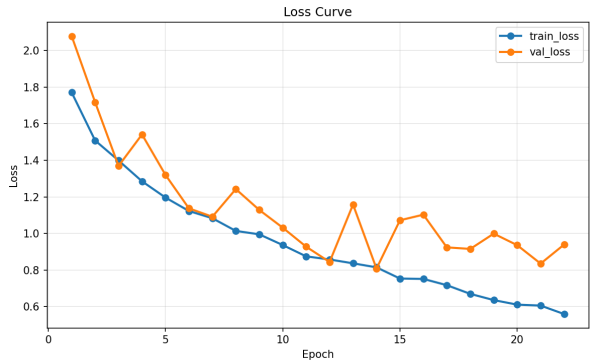

(a) exp8_improved_longer_12 Loss 曲线

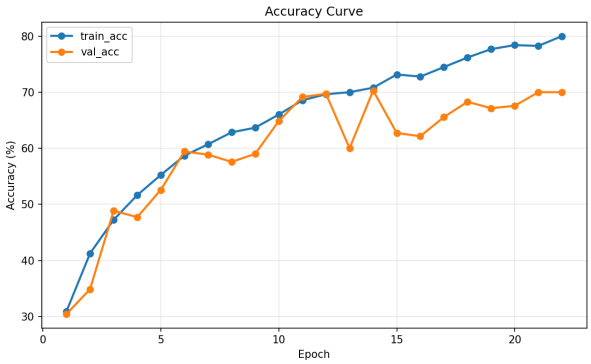

(b) exp8_improved_longer_12 Accuracy 曲线

图 6: `improved_longer_12`（12 个卷积层）在增强 + Adam 下的训练/验证曲线；约第 14 轮后验证准确率未再刷新，第 22 轮早停

6 混淆矩阵对比图

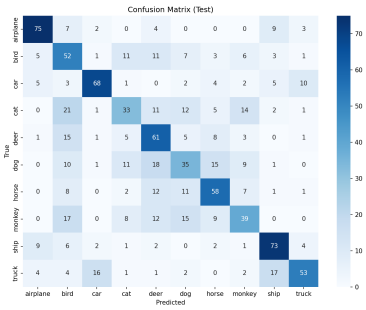

(a) baseline

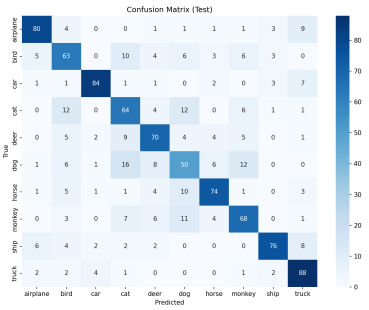

(b) exp2_aug_bn

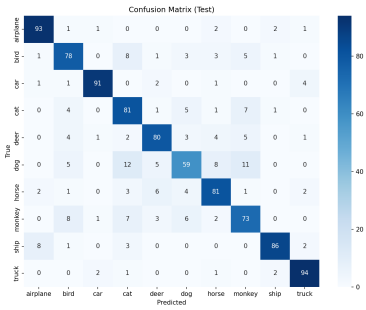

(c) exp7_improved_longer

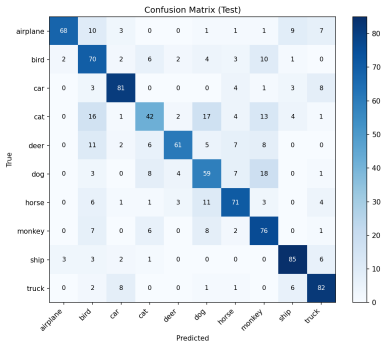

(d) exp8_improved_longer_12（12 层）

图 7: 测试集混淆矩阵对比（含 exp8；exp8 图文件名为 `exp8_improved_longer_12_improved_longer_12_confusion_`
因保存脚本将 `run_tag` 与 `model_name` 拼接）

7 结果分析

7.1 1) 有效实验与主要收益来源

从总体结果看，**数据增强**与**Batch Normalization** 仍是将 baseline（54.70%）抬升到可用水平的关键；`exp2_aug_bn` 在浅层 configurable 上达到 71.70%。`exp6_improved_long`（6 个卷积层）将测试准确率提升到 80.40%，验证峰值 82.71%。进一步将骨干加深为 `improved_longer`（**9** 个卷积层、无残差）后，`exp7_improved_longer` 在测试集上达到 **81.60%**，为**当前最高测试准确率**；说明在固定训练配方下，**适度增加卷积深度**仍有边际收益。`exp8_improved_longer_12` 在相同配方下将卷积层数增至 **12**，测试准确率降至 **69.50%**、验证峰值约 70.29%，训练在第 22 轮触发早停（最优验证在第 14 轮），表明在**不调整学习率、正则与训练轮次**的前提下，**继续堆叠卷积**反而损害泛化，可能因容量过大导致过拟合或优化 landscape 变差。

`exp1_aug` 相对 baseline 提升 11.80 个百分点，说明泛化不足是原始模型的主要瓶颈；`exp3_aug_dropout`（69.00%）表明在无 BN 时 Dropout 有帮助但仍难超过引入 BN 的浅层模型。

7.2 2) 优化器与学习率（exp4 / exp5）

`exp4_aug_bn_sgd` 与 `exp2` 结构完全一致，仅将优化器换为 SGD（`lr=0.01`），测试 70.30%，低于 `exp2` 的 71.70%，说明在该小网络上 Adam 更匹配当前训练配方。`exp5_aug_bn_lr` 将 Adam 学习率降到 `3e-4`，测试 69.80%，进一步说明**盲目降 lr 不一定提升**，需要与调度及有效 batch 统计等联合考虑。

7.3 3) 过拟合与模型深度

baseline 的 train_acc 接近 100% 而 val/test 明显偏低，属典型过拟合。数据增强与 BN 可显著缓解。exp6、exp7 等深模型借助 BN、Dropout 与池化，测试表现整体较好；exp7 在测试上略优于 exp6，而 exp6 的验证峰值更高，提示二者泛化特性略有不同。exp8 在更深骨干上验证与测试均明显低于 exp7，与 "深度—数据量—正则" 不匹配时的退化现象一致。

7.4 4) 最终测试集性能

当前测试集最优为 exp7_improved_longer：

- Test Accuracy = 81.60%
- Macro-F1 = 0.8153
- Weighted-F1 = 0.8153

exp6_improved_long 测试 80.40%、验证峰值更高（82.71%）；浅层 exp2_aug_bn 为 71.70%，可作轻量备选。exp8_improved_longer_12 测试 69.50%、Macro/Weighted-F1 约 0.6948，明显低于 exp7。

7.5 5) 方法优劣总结

- L2 正则化：各组统一 weight_decay=5e-4，不是组间差异的主要来源。
- 数据增强：相对 baseline 提升最大的一块基础能力。
- BatchNorm：与增强配合构成高质量浅层模型（exp2）。
- Dropout：在 exp3 中体现无 BN 时的正则价值；在深模型分类头中与 BN 配套。
- 更深网络：improved_long → improved_longer 持续提升测试精度；再增至 improved_longer_12（exp8）在本设置下**未**带来收益，说明深度需与数据规模及超参一并调节。
- 优化器/学习率：在固定 exp2 结构下，SGD 与过小 Adam lr 未超过原 exp2。

8 可解释性分析（Grad-CAM）

8.1 方法说明

Grad-CAM 用目标类别在 logits 上的标量得分对**最后一层卷积特征图**求梯度，把梯度在空间上做一次全局平均得到每个通道的权重，再对特征图通道加权求和并取 ReLU，得到一张与卷积特征同分辨率的类激活图，最后上采样到输入尺寸并伪彩色显示。直观上，它回答的是：模型为了把样本判成某一类，更依赖特征图里哪些空间位置（对应到原图大致落在哪些区域）。

本实验在最后一层 Conv2d 上挂钩实现（未改动网络结构），热力图对应当前预测类别的解释（即对 $\arg\max$ 类别的 Grad-CAM）。脚本使用与测试阶段一致的预处理（Resize/CenterCrop、 Normalize(0.5)）。

8.2 可视化设置

模型选用当前测试集表现最好的 `exp7_improved_longer` 分支对应的 checkpoint；从 STL-10 官方划分测试集中筛选样本，分别给出**预测正确**与**预测错误**两类可视化，结果保存在 `homework/figures/gradcam/`（含 `correct/`、`wrong/` 子目录）。本地复现可运行：

```
python src/run_gradcam.py --checkpoint outputs_improved/exp7_improved_longer/checkpoints/exp7_imp
```

8.3 结果展示

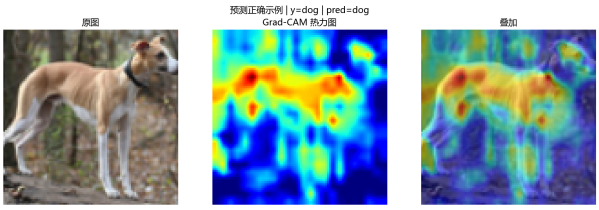

(a) 预测正确：热力图多集中在物体主体与轮廓附近

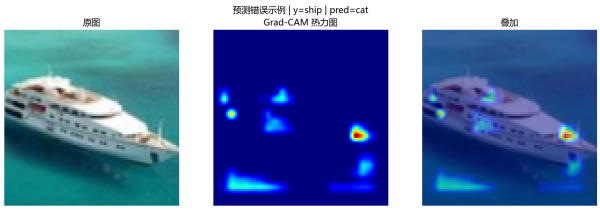

(b) 预测错误：高响应区域往往偏离标签语义或扩散到背景

图 8: Grad-CAM 对比（左：正确样本；右：错误样本；均为原图/热力图/叠加）

8.4 分析与讨论

STL-10 图像主体相对居中、背景相对干净，若模型学到的是可迁移的语义线索，热力图应主要覆盖物体部位而不是大片纯色背景。实验观察大致符合这一点：在预测正确的样本上，热点往往贴在物体外轮廓与内部纹理较强区域；这与人类判断“物体在哪”的经验较为一致。

在预测错误的样本上，更容易看到两类现象：一是响应分散或偏向边缘/角落，说明模型可能被局部噪声带走；二是热点落在与标签类别相近的部位但在细粒度上混淆（例如动物类之间），这时热力图不一定“乱”，但它强调的语义区域与真实标签不一致，提示模型仍在做“看起来像”的关联，而非完全稳健的高层语义。

8.5 小结

综合来看，模型并非只在像素层面做模板匹配：正确样本的可视化具有一定语义指向性；但错误样本说明决策仍会被背景或细粒度混淆干扰，距离“完全可靠的高层语义理解”仍有差距。这与测试集准确率约 81–82%（`exp7` / `exp6`）相吻合。

9 结论

本实验完成了 STL10 图像分类任务中的 baseline 与多组优化对比。结果表明：**数据增强 + BatchNorm** 可将浅层模型推到 71.70%；`improved_long` 与 `improved_longer` 等更深骨干使测试准确率最高达到 **81.60%**（`exp7`）。`exp8_improved_longer_12` 在 `exp7` 配方上继续加深至 12 个卷积层，测试仅 **69.50%**，说明在本数据与训练预算下**并非越深越好**。`exp4`（SGD）与 `exp5`（较小 Adam lr）在固定 `exp2` 结构下未超过原 Adam 配置。

Grad-CAM 可视化进一步表明模型在多数正确样本上会关注物体区域，但错误样本仍存在背景干扰与细粒度混淆，说明模型已经学到一定语义线索，但距离完全稳健的图像理解仍有改进空间。后续可继续尝试更精细的数据增强策略、学习率调度搜索和更深层网络结构，并结合更强的可解释性方法做对照。

附件与提交说明

按课程要求整理代码、说明文档与实验报告。可解释性脚本位于 `src/gradcam.py`（核心实现）与 `src/run_gradcam.py`（加载权重并导出图）。运行依赖 PyTorch 与 torchvision（与训练环境一致），数据路径默认 `STL10/`。