# STL10 图像分类模型优化实验报告

人工智能原理课程项目 2

2026 年 5 月 3 日

## 目录


**1 实验目标** **2**

**2 实验设置** **2**

**3 实验分组** **2**

**4 总体结果对比** **2**

**5 训练曲线展示** **3**

5.1 Baseline 曲线（过拟合明显） . . . . . 3

5.2 最佳实验 exp2_aug_bn 曲线 . . . . . 3

5.3 exp3_aug_bn_dropout 曲线 . . . . . 4

**6 混淆矩阵对比图** **4**

**7 结果分析** **4**

7.1 1) 有效实验与主要收益来源 . . . . . 4

7.2 2) 收益有限或需要重新调参的实验 . . . . . 4

7.3 3) 过拟合分析 . . . . . 5

7.4 4) 最终测试集性能 . . . . . 5

7.5 5) 方法优劣总结 . . . . . 5

**8 可解释性分析（Grad-CAM）** **5**

8.1 方法说明 . . . . . 5

8.2 可视化设置 . . . . . 6

8.3 结果展示 . . . . . 6

8.4 分析与讨论 . . . . . 6

8.5 小结 . . . . . 6

**9 结论** **6**

# 1 实验目标

基于 baseline CNN（至少 3 个卷积层和 1 个池化层），在 STL10 数据集上开展优化实验，重点比较：

- 数据增强是否提升泛化能力；
- BatchNorm 与 Dropout 对收敛和过拟合的影响；
- 优化器与学习率设置对最终测试表现的影响。

# 2 实验设置

- 数据来源：`STL10/train` 与 `STL10/test`。
- 训练配置：固定 `epochs=50`、`batch_size=128`、`val_ratio=0.1`、`seed=42`。
- 评估指标：Accuracy、Macro-F1、Weighted-F1、分类报告、混淆矩阵。
- 输出目录：`outputs_improved/`。

# 3 实验分组

- baseline：无增强、无 BN、无 Dropout（Adam, lr=0.001）
- exp1_aug：数据增强（RandomCrop + HorizontalFlip + ColorJitter）
- exp2_aug_bn：数据增强 + BatchNorm
- exp3_aug_bn_dropout：数据增强 + BatchNorm + Dropout(0.3)
- exp4_opt_adam / exp4_opt_sgd：在实验三基础上对比优化器与学习率
- exp5_best_combo：综合优化（AdamW, lr=0.0008）

# 4 总体结果对比

| 实验组 | Best Val Acc(%) | Test Acc(%) | Macro-F1 | Weighted-F1 |
|---|---|---|---|---|
| baseline | 61.43 | 54.70 | 0.5464 | 0.5464 |
| exp1_aug | 71.57 | 66.50 | 0.6688 | 0.6688 |
| exp2_aug_bn | **77.14** | **71.70** | **0.7178** | **0.7178** |
| exp3_aug_bn_dropout | 73.29 | 71.00 | 0.7099 | 0.7099 |
| exp4_opt_adam | 73.57 | 70.50 | 0.7053 | 0.7053 |
| exp4_opt_sgd | 74.57 | 71.60 | 0.7171 | 0.7171 |
| exp5_best_combo | 75.00 | 70.70 | 0.7067 | 0.7067 |

表 1: 各实验组性能对比（数据来自 `outputs_improved/comparison_summary.csv`）

# 5 训练曲线展示

## 5.1 Baseline 曲线（过拟合明显）

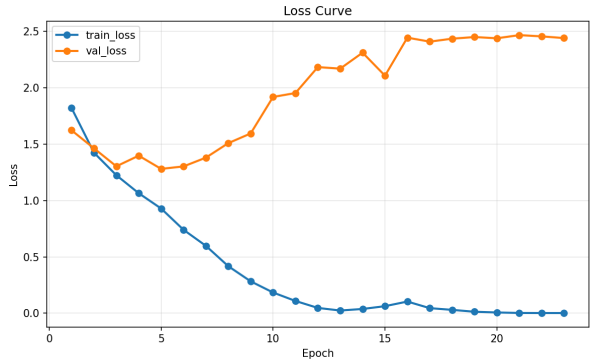


(a) Baseline Loss 曲线

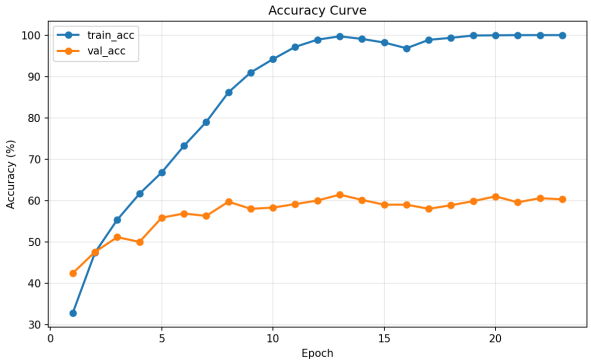


(b) Baseline Accuracy 曲线

图 1: baseline 训练/验证曲线

## 5.2 最佳实验 exp2_aug_bn 曲线

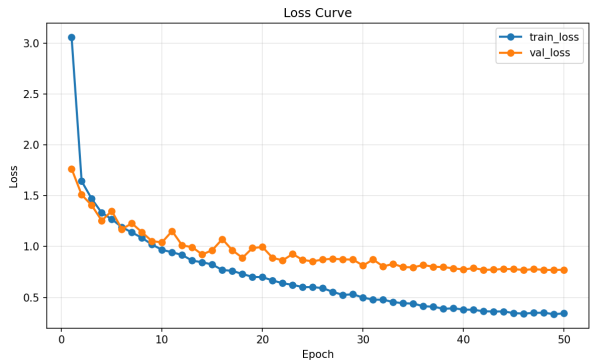


(a) exp2_aug_bn Loss 曲线

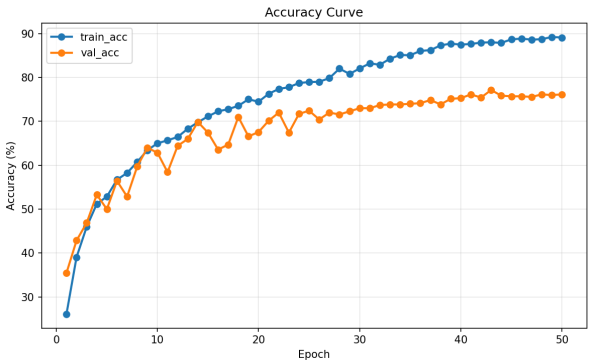


(b) exp2_aug_bn Accuracy 曲线

图 2: 数据增强 + BatchNorm 的训练/验证曲线

### 5.3 exp3_aug_bn_dropout 曲线

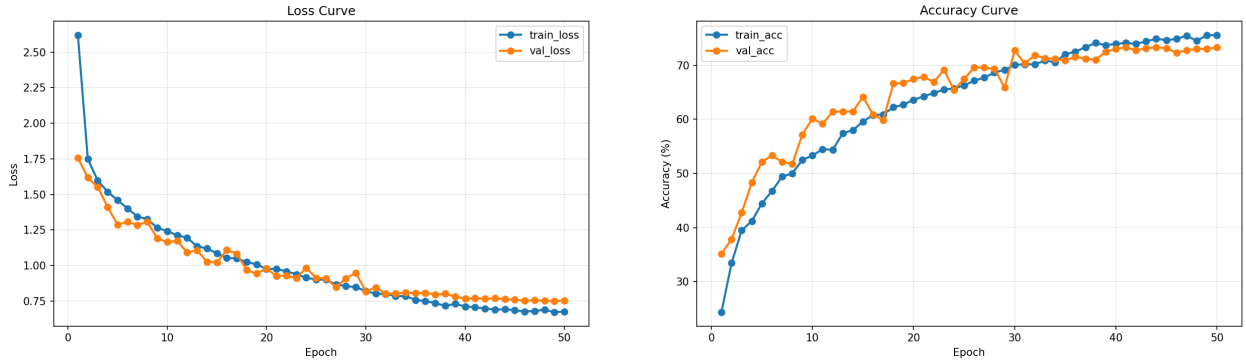


(a) exp3 Loss 曲线 (b) exp3 Accuracy 曲线

图 3: 数据增强 + BatchNorm + Dropout 的训练/验证曲线

# 6 混淆矩阵对比图

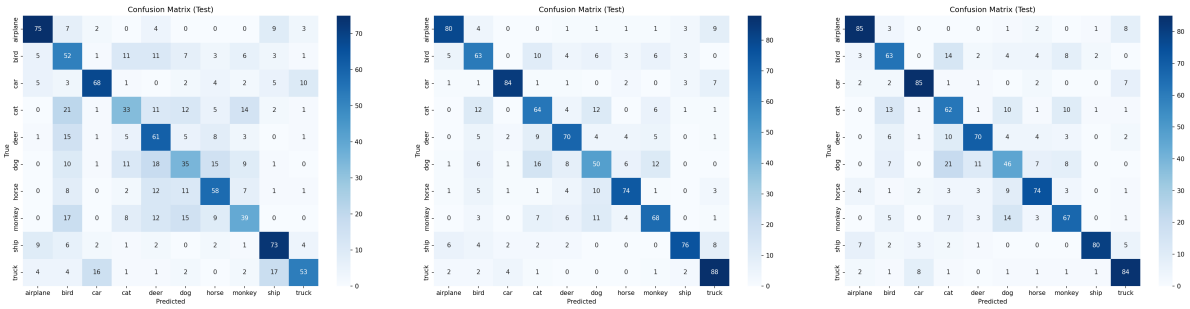


(a) baseline (b) exp2_aug_bn (c) exp4_opt_sgd

图 4: 测试集混淆矩阵对比

# 7 结果分析

## 7.1 1) 有效实验与主要收益来源

从总体结果看，本实验中最有效的两个改进是**数据增强**和 **Batch Normalization**。baseline 的测试准确率为 54.70%，加入随机裁剪、水平翻转和颜色扰动后，`exp1_aug` 提升到 66.50%，绝对提升 11.80 个百分点，说明原始 baseline 的主要问题是泛化能力不足。进一步加入 BatchNorm 后，`exp2_aug_bn` 达到最高测试准确率 71.70%，相比 baseline 绝对提升 17.00 个百分点，是本组实验中最有价值的配置。

BatchNorm 的收益主要体现在两方面：一是稳定中间特征分布，使训练过程更平稳；二是在数据增强已经扩大样本扰动范围后，帮助模型更好地适应不同输入分布。因此，`exp2_aug_bn` 同时取得最高 Best Val Acc、Test Acc、Macro-F1 和 Weighted-F1，可作为最终推荐模型。

## 7.2 2) 收益有限或需要重新调参的实验

`exp3_aug_bn_dropout` 在 `exp2` 的基础上加入 Dropout(0.3)，测试准确率为 71.00%，略低于 `exp2_aug_bn`。这说明 Dropout 确实有抑制过拟合的作用，但当前 0.3 的强度并没有带来额外收益，可能已经削弱了特征表达能力。后续若继续使用 Dropout，应尝试 0.1 或 0.2，并与学习率重新配合调参。

`exp4_opt_adam` 与 `exp4_opt_sgd` 用于比较优化器。结果显示 Adam 分支为 70.50%，SGD 分支为 71.60%，二者差距不大，SGD 略优但没有超过 `exp2_aug_bn`。因此优化器调整属于细节优化，收益小于数据增强和 BatchNorm。`exp5_best_combo` 使用 AdamW 和更小学习率，测试准确率为 70.70%，也未超过 `exp2`，说明简单叠加正则化和优化器改动并不必然提升效果。

### 7.3 3) 过拟合分析

baseline 的 train_acc 接近 100%，而 val_acc 和 test_acc 明显偏低，属于典型过拟合。数据增强能显著缓解这一问题，因为它让模型在训练阶段看到更多位置、颜色和局部形变变化；BatchNorm 进一步提高了训练稳定性和泛化上限。相比之下，Dropout 和残差连接虽然理论上有助于泛化和深层训练，但在当前任务和超参数下并不是主要收益来源。

### 7.4 4) 最终测试集性能

最优实验为 `exp2_aug_bn`：

- Test Accuracy = 71.70%
- Macro-F1 = 0.7178
- Weighted-F1 = 0.7178

相比 baseline（54.70%），绝对提升约 17 个百分点，说明“数据增强 + BatchNorm”是最有效的优化策略。

### 7.5 5) 方法优劣总结

- 数据增强：从 54.70% 提升到 66.50%，是最关键的泛化改进。
- BatchNorm：在数据增强基础上进一步提升到 71.70%，是最终最优组合。
- Dropout：当前 0.3 设置收益有限，可能偏强，需要重新调参。
- 优化器对比：SGD(0.01) 与 Adam(0.001) 接近，SGD 分支略优，但不是决定性因素。

## 8 可解释性分析（Grad-CAM）

### 8.1 方法说明

Grad-CAM 用目标类别在 logits 上的标量得分对**最后一层卷积特征图**求梯度，把梯度在空间上做一次全局平均得到每个通道的权重，再对特征图通道加权求和并取 ReLU，得到一张与卷积特征同分辨率的类激活图，最后上采样到输入尺寸并伪彩色显示。直观上，它回答的是：模型为了把样本判成某一类，更依赖特征图里哪些空间位置（对应到原图大致落在哪些区域）。

本实验在最后一层 `Conv2d` 上挂钩实现（未改动网络结构），热力图对应当前预测类别的解释（即对 $\arg\max$ 类别的 Grad-CAM）。脚本使用与测试阶段一致的预处理（Resize/CenterCrop、Normalize(0.5)）。

## 8.2 可视化设置

模型选用测试集表现最好的 `exp2_aug_bn` 分支对应的 checkpoint；从 STL-10 官方划分测试集中筛选样本，分别给出**预测正确**与**预测错误**两类可视化，结果保存在 `homework/figures/gradcam/`（含 `correct/`、`wrong/` 子目录）。本地复现可运行：

```
python src/run_gradcam.py --checkpoint outputs_improved/exp2_aug_bn/checkpoints/exp2_aug_bn_best.
```

## 8.3 结果展示

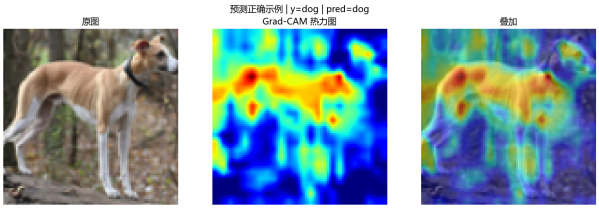


(a) 预测正确：热力图多集中在物体主体与轮廓附近

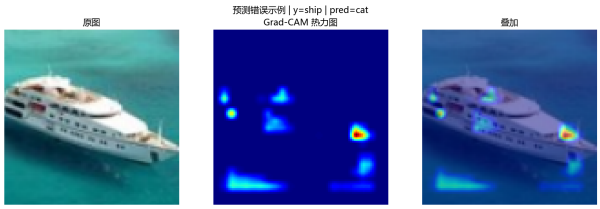


(b) 预测错误：高响应区域往往偏离标签语义或扩散到背景

图 5: Grad-CAM 对比（左：正确样本；右：错误样本；均为原图/热力图/叠加）

## 8.4 分析与讨论

STL-10 图像主体相对居中、背景相对干净，若模型学到的是可迁移的语义线索，热力图应主要覆盖物体部位而不是大片纯色背景。实验观察大致符合这一点：在预测正确的样本上，热点往往贴在物体外轮廓与内部纹理较强区域；这与人类判断“物体在哪”的经验较为一致。

在预测错误的样本上，更容易看到两类现象：一是响应分散或偏向边缘/角落，说明模型可能被局部噪声带走；二是热点落在与标签类别相近的部位但在细粒度上混淆（例如动物类之间），这时热力图不一定“乱”，但它强调的语义区域与真实标签不一致，提示模型仍在做“看起来像”的关联，而非完全稳健的高层语义。

## 8.5 小结

综合来看，模型并非只在像素层面做模板匹配：正确样本的可视化具有一定语义指向性；但错误样本说明决策仍会被背景或细粒度混淆干扰，距离“完全可靠的高层语义理解”仍有差距。这与测试集准确率约 72%（相对 baseline 明显提升但仍有限）相吻合。

# 9 结论

本实验完成了 STL10 图像分类任务中的 baseline 与多组优化对比。结果表明：在当前数据与配置下，**数据增强 + BatchNorm** 是最优组合，测试准确率达到 71.70%，显著优于 baseline 的 54.70%。数据增强主要改善泛化能力，BatchNorm 进一步稳定训练并提高性能上限；Dropout、AdamW 和优化器替换在当前设置下没有超过该组合。

Grad-CAM 可视化进一步表明模型在多数正确样本上会关注物体区域，但错误样本仍存在背景干扰与细粒度混淆，说明模型已经学到一定语义线索，但距离完全稳健的图像理解仍有改进空间。后续可继续尝试更精细的数据增强策略、学习率调度搜索和更深层网络结构，并结合更强的可解释性方法做对照。

# 附件与提交说明

按课程要求整理代码、说明文档与实验报告。可解释性脚本位于 `src/gradcam.py`（核心实现）与 `src/run_gradcam.py`（加载权重并导出图）。运行依赖 PyTorch 与 torchvision（与训练环境一致），数据路径默认 `STL10/`。