STL10 图像分类模型优化实验报告

人工智能原理课程· 项目二· STL10 图像分类

院　　系：	自动化系
班　　级：	自52班
学 生 姓 名：	刘江宇
学　　号：	2024013215
课 程 名 称：	人工智能原理

目录

1 实验目标 **2**

2 实验设置 **2**

3 实验分组 **2**

4 实验结果概览 **3**

5 训练过程与结果分析 **3**

5.1 （一）baseline → exp1：数据增强 3
5.2 （二）exp1 → exp2：BatchNorm 4
5.3 （三）exp2 → exp3：Dropout（与 BN 路径对照） 4
5.4 （四）exp2 → exp4：优化器（Adam vs SGD） 5
5.5 （五）exp2 → exp5：学习率 5
5.6 （六）exp2 → exp6 / exp7 / exp8：网络深度 5

6 可解释性分析（Grad-CAM） **6**

6.1 方法说明 6
6.2 可视化设置 7
6.3 结果展示 7
6.4 分析与讨论 7
6.5 小结 7

7 结论 **7**

1 实验目标

基于 baseline CNN，在 STL10 数据集上开展优化实验，尝试在模型训练过程当中可能会影响模型效果的因素，更好地掌握上课学习到的内容重点比较不同因素对模型效果的影响，包括：

- 数据增强是否提升泛化能力；
- BatchNorm 与 Dropout 对收敛和过拟合的影响；
- 优化器与学习率设置对最终测试表现的影响；
- 更深网络（`improved_long`，多段池化）相对浅层 configurable 的收益。

同时还通过Grad-CAM进行可解释性的分析，更好地理解模型为什么能够做出这样的预测

2 实验设置

- 数据来源：`STL10/train` 与 `STL10/test`。（课程提供）
- 训练配置：固定 `epochs=50`、`batch_size=128`、`val_ratio=0.1`、`seed=42`。
- 评估指标：Accuracy、Macro-F1、Weighted-F1、分类报告、混淆矩阵。
- 输出目录：`outputs_improved/`。（可在压缩包或github上查看）

3 实验分组

实验主要有8组，分别在baseline的基础上进行修改，包括数据增强、BatchNorm、Dropout、优化器、学习率、网络深度等

- baseline：基础 CNN，无增强、无 BN、无 Dropout（Adam, lr=0.001, L2 `weight_decay=5e-4`）
- exp1_aug：数据增强（RandomCrop + HorizontalFlip + ColorJitter）
- exp2_aug_bn：数据增强 + BatchNorm
- exp3_aug_dropout：数据增强 + Dropout(0.3)
- exp4_aug_bn_sgd：与 exp2 相同（增强 + BN、无 Dropout），优化器改为 SGD（`lr=0.01`）
- exp5_aug_bn_lr：与 exp2 相同，Adam 学习率改为 `3e-4`
- exp6_improved_long_6：与 exp2 相同，卷积层数改为6
- exp7_improved_long_9：与 exp2 相同，卷积层数改为9
- exp8_improved_longer_12：与 exp2 相同，卷积层数改为12

4 实验结果概览

下面附上全部实验的实验结果，其中test成功率最低的为baseline，为54.70%，最高的为exp7_improved_long_9，为81.60%。详细的训练分析在后面会给出

实验组	Best Val Acc(%)	Test Acc(%)	Macro-F1	Weighted-F1
baseline	61.43	54.70	0.5464	0.5464
exp1_aug	71.57	66.50	0.6688	0.6688
exp2_aug_bn	77.14	71.70	0.7178	0.7178
exp3_aug_dropout	74.14	69.00	0.6918	0.6918
exp4_aug_bn_sgd	74.57	70.30	0.7052	0.7052
exp5_aug_bn_lr	74.43	69.80	0.6959	0.6959
exp6_improved_long_6	82.71	80.40	0.8055	0.8055
exp7_improved_long_9	81.57	**81.60**	**0.8153**	**0.8153**
exp8_improved_longer_12	70.29	69.50	0.6948	0.6948

表 1: 各实验组性能对比（见 `comparison_summary.csv`）

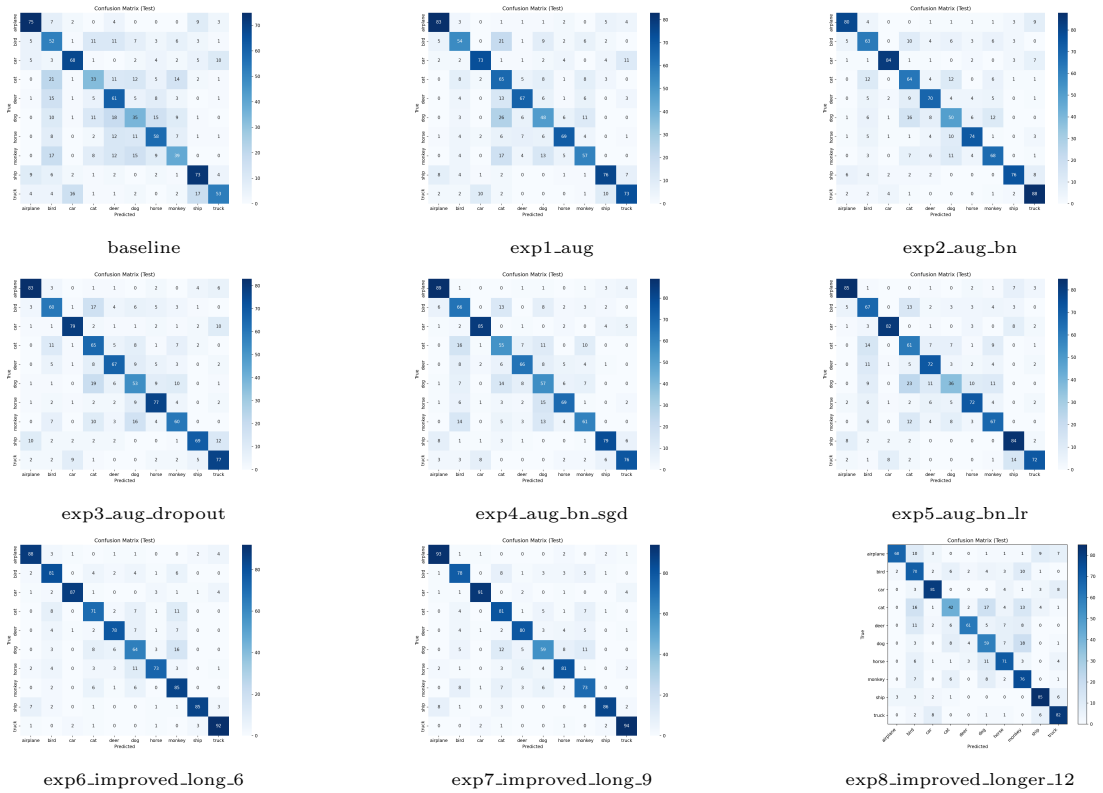

图 1: 测试集混淆矩阵（3×3）

5 训练过程与结果分析

下面按对照分组放了训练曲线：每张图从左到右是训练/验证的 loss 和准确率，虚线是参照组、实线是对照组。数字以表 1 为准，图主要是看收敛快慢和 train、val 差得大不大。

5.1 （一）baseline → exp1：数据增强

- baseline 测试只有 54.70%，exp1 拉到 66.50%，成功率提升很多

- 从曲线上看，baseline的过拟合非常严重，exp1的过拟合程度明显减轻，说明数据增强确实有效果

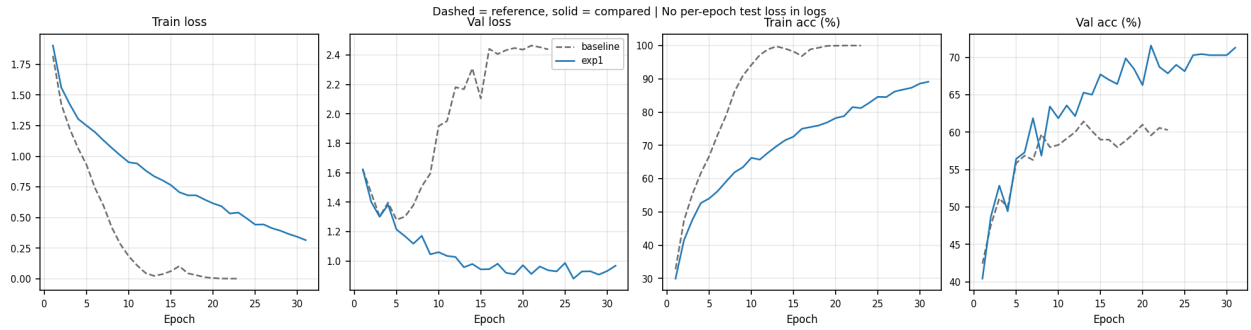

图 2: baseline（虚线）与 exp1_aug（实线）：训练/验证 loss 与准确率

5.2 （二）exp1 → exp2：BatchNorm

- exp1 测试 66.50%，exp2 到 71.70%，又涨了 5 个点左右，说明在已经有增强的前提下，加上 BN 还是有效减小了过拟合。

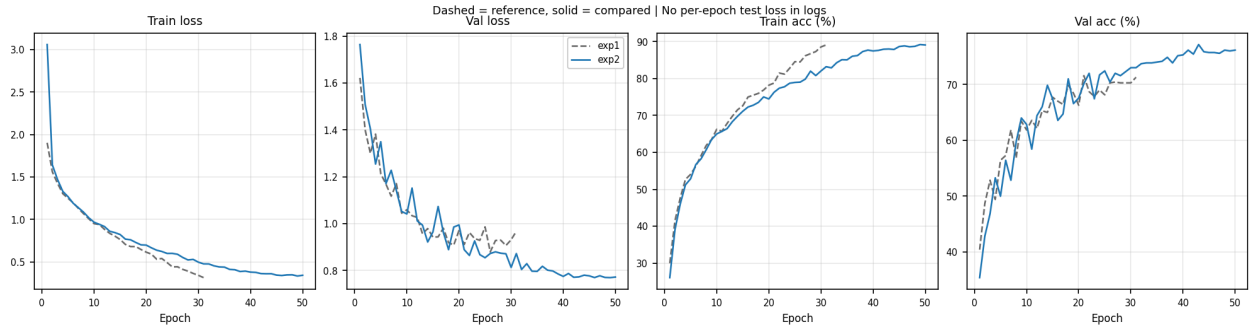

图 3: exp1_aug（虚线）与 exp2_aug_bn（实线）

5.3 （三）exp2 → exp3：Dropout（与 BN 路径对照）

- exp2 测试 71.70%，exp3 只有 69.00%，但都比baseline好。说明两种办法都很有效，且差异并没有很大。

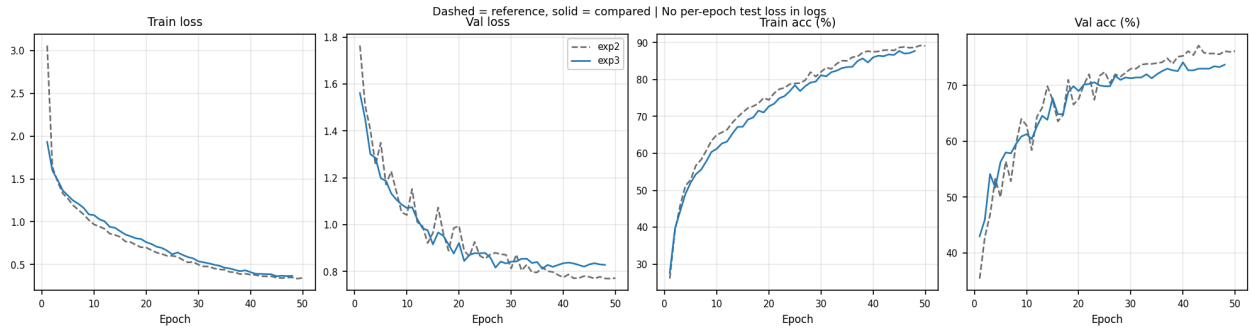

图 4: exp2_aug_bn（虚线）与 exp3_aug_dropout（实线）

5.4 （四）exp2 → exp4：优化器（Adam vs SGD）

- 不同的优化器对比，exp2（Adam）测试 71.70%，exp4（SGD）70.30%，差得不大，但确实是 exp2 略好一点。

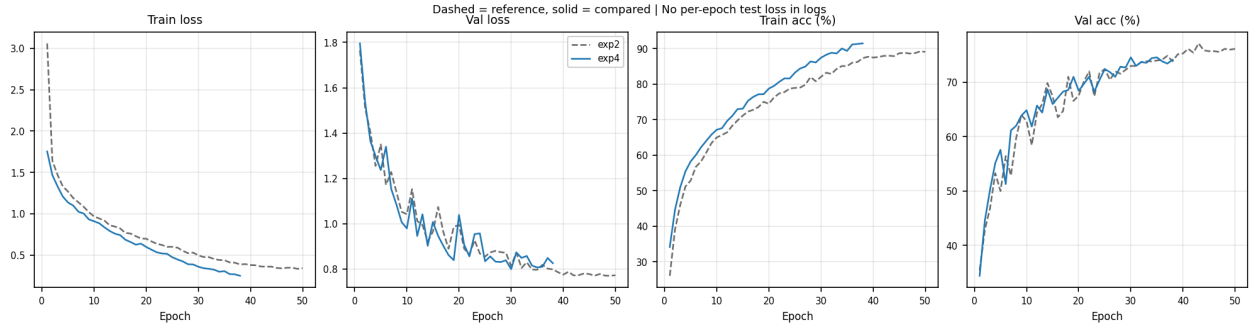

图 5: exp2_aug_bn（虚线）与 exp4_aug_bn_sgd（实线）

5.5 （五）exp2 → exp5：学习率

- exp2 用 `1e-3`，exp5 改成 `3e-4`，测试从 71.70% 掉到 69.80% 左右，说明这次并不是学习率越小越稳越好。

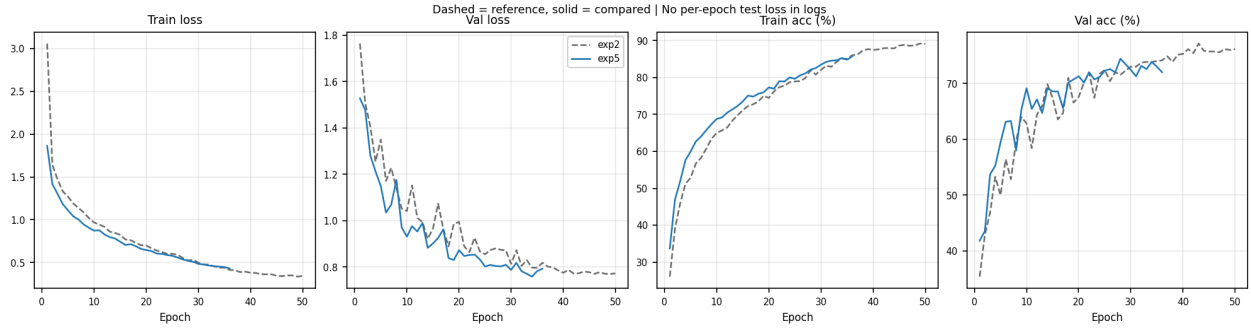

图 6: exp2_aug_bn（虚线）与 exp5_aug_bn_lr（实线）

5.6 （六）exp2 → exp6 / exp7 / exp8：网络深度

- 浅层 exp2 测试 71.70%，加深以后 exp6 到 80.40%、exp7 到 81.60%（全队最高），说明在一定范围内增加网络深度可以有效提升模型效果。
- exp8 又掉到 69.50%，跟 exp7 差了一大截，说明模型也不是越深越好

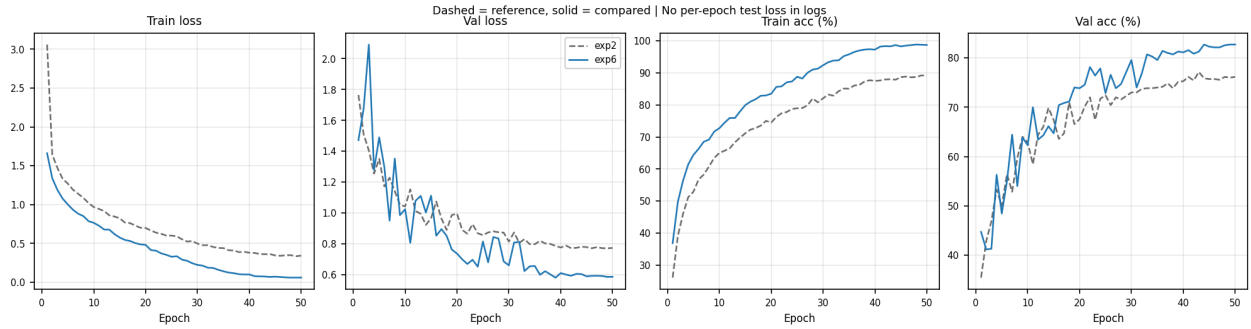

图 7: exp2_aug_bn（虚线）与 exp6_improved_long_6（实线）

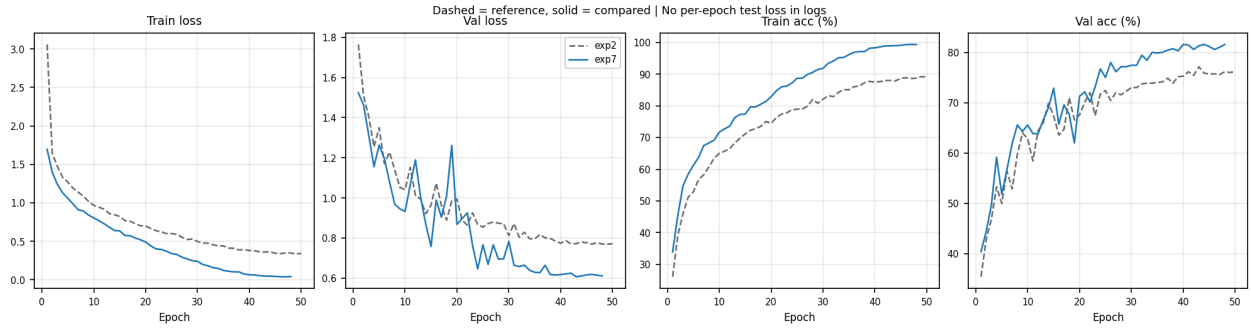

图 8: exp2_aug_bn（虚线）与 exp7_improved_long_9（实线）

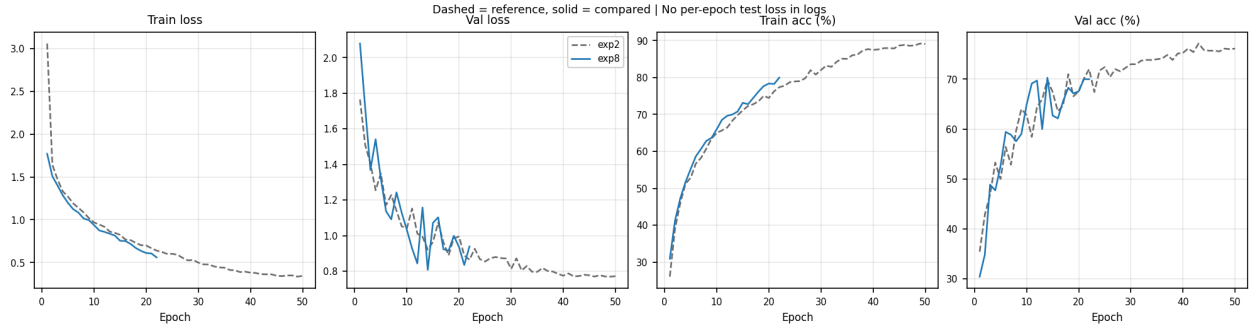

图 9: exp2_aug_bn（虚线）与 exp8_improved_longer_12（实线）

6 可解释性分析（Grad-CAM）

6.1 方法说明

Grad-CAM 用目标类别在 logits 上的标量得分对**最后一层卷积特征图**求梯度，把梯度在空间上做一次全局平均得到每个通道的权重，再对特征图通道加权求和并取 ReLU，得到一张与卷积特征同分辨率的类激活图，最后上采样到输入尺寸并伪彩色显示。直观上，它回答的是：模型为了把样本判成某一类，更依赖特征图里哪些空间位置（对应到原图大致落在哪些区域）。

本实验在最后一层 `Conv2d` 上挂钩实现（未改动网络结构），热力图对应当前预测类别的解释（即对 $\arg\max$ 类别的 Grad-CAM）。脚本使用与测试阶段一致的预处理（Resize/CenterCrop、 Normalize(0.5)）。

6.2 可视化设置

模型选用当前测试集表现最好的 `exp7_improved_long_9` 分支对应的 checkpoint；从 STL-10 官方划分测试集中筛选样本，分别给出**预测正确**与**预测错误**两类可视化，结果保存在 `homework/figures/gradcam/`（含 `correct/`、`wrong/` 子目录）。本地复现可运行：

```
python src/run_gradcam.py --checkpoint outputs_improved/exp7_improved_long_9/checkpoints/exp7_imp
```

6.3 结果展示

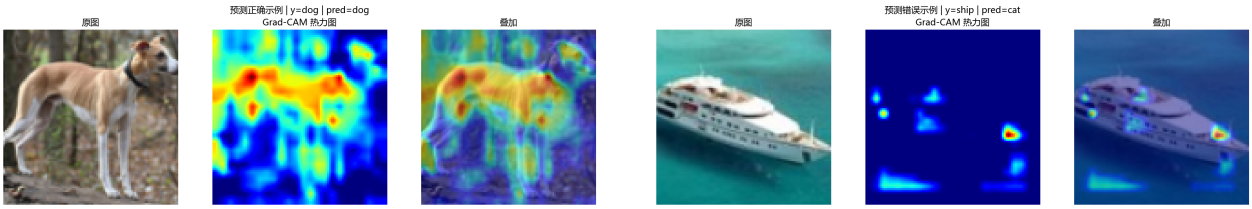

(a) 预测正确：热力图多集中在物体主体与轮廓附近　　(b) 预测错误：高响应区域往往偏离标签或扩散到背景

图 10: Grad-CAM 对比（左：正确样本；右：错误样本；均为原图/热力图/叠加）

6.4 分析与讨论

STL-10 图像主体相对居中、背景相对干净，若模型学到的是可迁移的语义线索，热力图应主要覆盖物体部位而不是大片纯色背景。实验观察大致符合这一点：在预测正确的样本上，热点往往贴在物体外轮廓与内部纹理较强区域；这与人类判断“物体在哪”的经验较为一致。

在预测错误的样本上，更容易看到两类现象：一是响应分散或偏向边缘/角落，说明模型可能被局部噪声带走；二是热点落在与标签类别相近的部位但在细粒度上混淆（例如动物类之间），这时热力图不一定“乱”，但它强调的语义区域与真实标签不一致，提示模型仍在做“看起来像”的关联，而非完全稳健的高层语义。

6.5 小结

综合来看，模型并非只在像素层面做模板匹配：正确样本的可视化具有一定语义指向性；但错误样本说明决策仍会被背景或细粒度混淆干扰，距离“完全可靠的高层语义理解”仍有差距。这与测试集准确率约 81–82%（`exp7` / `exp6`）相吻合。

7 结论

本实验完成了 STL10 图像分类任务中的 baseline 与多组优化对比。结果表明：**数据增强 + BatchNorm** 可将浅层模型推到 71.70%；`improved_long` 与 `improved_longer` 等更深骨干使测试准确率最高达到 **81.60%**（`exp7`）。`exp8_improved_longer_12` 在 `exp7` 配方上继续加深至 12 个卷积层，测试仅 **69.50%**，说明在本数据与训练预算下**并非越深越好**。`exp4`（SGD）与 `exp5`（较小 Adam lr）在固定 `exp2` 结构下未超过原 Adam 配置。

Grad-CAM 可视化进一步表明模型在多数正确样本上会关注物体区域，但错误样本仍存在背景干扰与细粒度混淆，说明模型已经学到一定语义线索，但距离完全稳健的图像理解仍有改进空间。后续可继续尝试更精细的数据增强策略、学习率调度搜索和更深层网络结构，并结合更强的可解释性方法做对照。

附件与提交说明

按课程要求整理代码、说明文档与实验报告。可解释性脚本位于 `src/gradcam.py`（核心实现）与 `src/run_gradcam.py`（加载权重并导出图）。对照实验训练曲线（`cmp_01_baseline_exp1.png` 等共 8 张）由 `src/plot_comparison_curves.py` 写入 `homework/figures/comparisons/`。运行依赖 PyTorch 与 torchvision（与训练环境一致），数据路径默认 `STL10/`。